Red neuronal simple

Reporte de experimento, código y conclusiones

Sebastián Machado Parra

11 de octubre de 2026

Introducción y objetivo

Este reporte mide cómo afectan tres hiperparámetros (épocas, tasa de aprendizaje y tamaño de lote) al aprendizaje de una red neuronal pequeña que predice la calidad de vinos tintos.

El punto de partida es la plantilla que compartió el profesor: un script en PyTorch (`red_neuronal.py`) que predice la demanda de comida con una red 5 → 16 → 8 → 1, optimizador Adam, pérdida MSE, 100 épocas, tasa de aprendizaje 0.001 y lote de 64. Sus diapositivas explican qué se espera, en teoría, de cada hiperparámetro.

Aquí se adapta la misma plantilla a otro conjunto de datos y se contrasta cada expectativa teórica con resultados medidos.

Datos y preprocesamiento

El conjunto es Red Wine Quality (Kaggle): 1,599 vinos tintos con 11 variables químicas de entrada y la calificación `quality` como objetivo (de 3 a 8, promedio 5.64). No tiene valores vacíos.

- **Entradas:** fixed acidity, volatile acidity, citric acid, residual sugar, chlorides, free sulfur dioxide, total sulfur dioxide, density, pH, sulphates y alcohol.
- **División:** 1,023 filas para entrenamiento, 256 para validación y 320 para prueba.
- **Escalado de entradas:** `StandardScaler` ajustado solo con los datos de entrenamiento, para evitar fuga de información hacia validación y prueba.
- **Escalado del objetivo:** también se estandariza `quality`, de modo que una pérdida de 1.0 equivale a predecir siempre el promedio. Las métricas finales se calculan de nuevo en puntos de calidad.

Modelo y metodología

Se conserva la arquitectura de la plantilla, ajustada a 11 entradas: 11 → 16 → 8 → 1 con activación ReLU en las capas ocultas y 337 parámetros. Se entrena con Adam y pérdida MSE.

En cada experimento se cambia un solo hiperparámetro y los demás quedan en su valor base.

Hiperparámetro	Valores probados	Base
Épocas	30, 100, 300	100
Tasa de aprendizaje	0.0001, 0.001, 0.01, 0.1	0.001
Tamaño de lote	16, 64, 256	64

Cada configuración se entrenó 3 veces con semillas distintas, que cambian la inicialización de los pesos y el orden de los lotes. La división de los datos es la misma en todas las corridas. Los resultados son el promedio de las 3 semillas, con su desviación estándar (±).

Se reportan la pérdida de validación por época, la brecha entre validación y entrenamiento (más grande indica más sobreajuste) y, sobre el conjunto de prueba, el error absoluto medio (MAE) en puntos de calidad y el R^2.

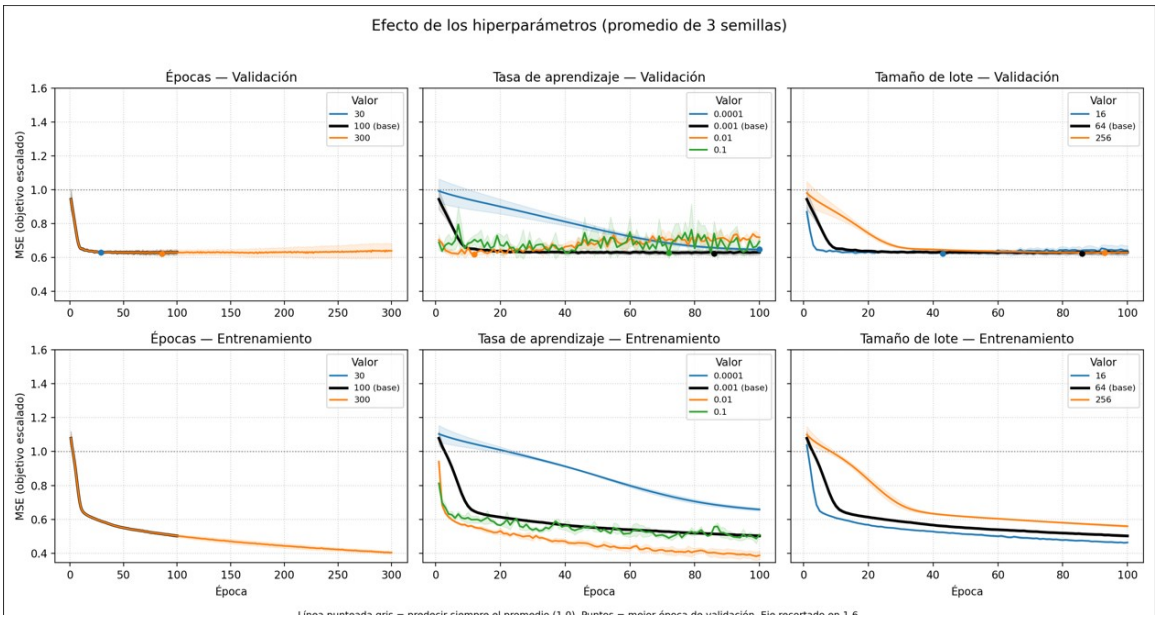
Resultados

La configuración base (100 épocas, tasa 0.001, lote 64) obtuvo el menor MAE de prueba, 0.491, y la tasa de aprendizaje resultó el hiperparámetro más sensible.

Como referencia, en la corrida individual del script base la red tuvo un MAE de 0.489 y un R^2 de 0.428. Una regresión lineal obtuvo un R^2 de 0.410, y predecir siempre el promedio daría un MAE de 0.683.

Variable	Valor	Mejor época de validación	MSE entrenamiento (final)	MSE validación (final)	Brecha	MAE prueba	R^2 prueba
Épocas	30	29	0.588	0.633	+0.046	0.499 ± 0.005	0.429 ± 0.006
Base	100	86	0.502	0.631	+0.129	0.491 ± 0.003	0.439 ± 0.005
Épocas	300	86	0.404	0.640	+0.236	0.494 ± 0.004	0.414 ± 0.016
Tasa de aprendizaje	0.0001	100	0.658	0.647	-0.011	0.522 ± 0.006	0.379 ± 0.013
Tasa de aprendizaje	0.01	12	0.388	0.719	+0.332	0.515 ± 0.003	0.343 ± 0.011
Tasa de aprendizaje	0.1	72	0.509	0.695	+0.186	0.531 ± 0.019	0.304 ± 0.056
Tamaño de lote	16	43	0.464	0.642	+0.178	0.493 ± 0.008	0.420 ± 0.009
Tamaño de lote	256	93	0.560	0.630	+0.071	0.494 ± 0.004	0.440 ± 0.007

La fila base es la misma para las tres familias: 100 épocas, tasa 0.001 y lote 64. La brecha es el MSE de validación menos el de entrenamiento al final del entrenamiento.



La figura muestra la pérdida de validación (arriba) y de entrenamiento (abajo) por época, promediada sobre 3 semillas, para cada hiperparámetro. La línea punteada en 1.0 es el nivel de predecir siempre el promedio, los puntos marcan la mejor época de validación y las bandas sombreadas son la desviación entre semillas.

Épocas

- Pasar de 30 a 100 épocas apenas cambia el resultado: el R^2 sube de 0.429 a 0.439, una diferencia cercana a la desviación entre semillas.
- Con 300 épocas el MSE de entrenamiento baja a 0.404, pero el de validación sube a 0.640. La brecha crece a +0.236 y el R^2 cae a 0.414 ± 0.016.
- La mejor época de validación es la 86 tanto con 100 como con 300 épocas.

Tasa de aprendizaje

- Con 0.0001 hay subajuste: entrenamiento y validación quedan en ~0.65 y la mejor época es la 100, es decir, seguía mejorando. El R^2 es 0.379.
- Con 0.01 la red aprende rápido y se sobreajusta: la mejor época es la 12, la brecha llega a +0.332 y el R^2 es 0.343.
- Con 0.1 el resultado es el peor y el más inestable: R^2 de 0.304 ± 0.056, la mayor desviación de todas las configuraciones.
- La curva de validación con 0.001 es la más suave y la más baja, alrededor de 0.63.

Tamaño de lote

- Los lotes de 64 y 256 dan el mismo resultado: validación de ~0.63 y R^2 de 0.439 y 0.440. El lote de 256 es más lento, pues tarda aproximadamente 40 épocas en llegar a la meseta, contra unas 12 del lote de 64.

- El lote de 16 llega en unas 5 épocas, pero se sobreajusta antes: mejor época 43, brecha de +0.178 y R^2 de 0.420.
- El número de actualizaciones por época cambia mucho: 64 con lote 16, 16 con lote 64 y 4 con lote 256 (con 1,023 filas de entrenamiento).

Discusión

Los resultados coinciden con la teoría de las diapositivas en tasa de aprendizaje y épocas, y la contradicen en parte en tamaño de lote.

- **Tasa de aprendizaje.** Las diapositivas dicen que una tasa baja da pasos diminutos y convergencia lenta, y que una excesiva provoca oscilaciones. Eso es lo observado: 0.0001 sigue mejorando al terminar y 0.01 y 0.1 oscilan por encima de la curva base. Con 0.1 no hubo divergencia a NaN, probablemente porque Adam normaliza el paso por parámetro, pero el resultado fue el peor. El script original trae 0.1 aunque sus comentarios y las diapositivas indican 0.001; con ese valor el modelo aprendería peor.
- **Épocas.** La teoría describe subajuste con pocas épocas y sobreajuste con demasiadas. Aquí 30 épocas no muestran subajuste claro, mientras que 300 abren la brecha hasta +0.236 sin mejorar la validación. Detener el entrenamiento cerca de la época 86 (parada temprana) coincide con lo que proponen las diapositivas.
- **Tamaño de lote.** Las diapositivas presentan 64 como punto dulce y dicen que el lote completo tiende a sobreajustar. Con lote 256 no se observa ese efecto: iguala a 64 y solo es más lento. No se probó el lote completo (1,023 filas), y como el número de actualizaciones por época cambia con el lote, ambos efectos quedan mezclados.
- **Capacidad del modelo.** La red alcanza un R^2 de 0.439, apenas por encima del 0.410 de una regresión lineal. La calidad de un vino es una calificación subjetiva y los datos parecen tener un techo, de modo que ajustar hiperparámetros mejora poco.

Limitaciones

Las diferencias pequeñas entre configuraciones no son concluyentes, por las siguientes razones.

- **División de datos fija.** Las semillas cambian la inicialización y el orden de los lotes, pero no la partición entrenamiento, validación y prueba. La variación debida a la partición no está medida.
- **Pocas repeticiones.** Con solo 3 semillas por configuración, las desviaciones estándar son aproximadas.
- **Conjunto de prueba pequeño.** Son 320 filas, y el "menor MAE de prueba" se elige mirando ese mismo conjunto. En varios casos la diferencia es menor que dos desviaciones.
- **Épocas con la misma trayectoria.** Las corridas de 30, 100 y 300 épocas comparten semillas, así que son la misma trayectoria cortada en distintos puntos.
- **Un hiperparámetro a la vez.** No se exploran interacciones, como la entre lote y tasa de aprendizaje.
- **Parámetros no probados.** Quedan fuera arquitectura, función de activación, optimizador y función de pérdida, que también se tratan en las diapositivas.

Conclusiones

La configuración base de la plantilla ya es casi la mejor posible para este conjunto de datos, y solo la tasa de aprendizaje la empeora de forma clara.

1. **La base es casi óptima.** Con 100 épocas, tasa 0.001 y lote 64 se obtuvo un MAE de 0.491 y un R^2 de 0.439.
2. **La tasa de aprendizaje es el hiperparámetro más sensible.** Con 0.0001, 0.01 y 0.1 el R^2 baja a 0.379, 0.343 y 0.304.
3. **Más épocas no ayudan.** Con 300 la brecha llega a +0.236 sin mejorar la validación, y la mejor época es la 86.
4. **El lote cambia la velocidad más que el resultado.** Los lotes de 64 y 256 son equivalentes, y el de 16 se sobreajusta antes.
5. **El límite lo pone el conjunto de datos.** La red supera por poco a la regresión lineal (R^2 de 0.428 contra 0.410 en la corrida base).

Anexo: conjuntos de datos descartados

Antes de Red Wine Quality se probaron otros dos conjuntos, y ninguno sirvió para el análisis.

- **CIFAR-10 Preprocessed (Kaggle).** Se descartó porque viene en formato `.pickle` (el archivo principal pesa ~1.2 GB) y el enunciado pedía un CSV.
- **heart_disease.csv (Kaggle).** Tiene 10,000 filas y 21 columnas, con `Heart Disease Status` (Yes/No) como objetivo y 20% de casos "Yes". La red logró una accuracy de 54.6% en prueba, menor que el 80% de responder siempre "No", con precision de 0.19 y recall de 0.38 en la clase "Yes". La pérdida de validación subió de 1.11 a 1.26 mientras la de entrenamiento bajaba a 0.97.

Un diagnóstico con regresión logística y Random Forest dio un AUC de 0.487 y 0.496, es decir, azar (0.5). El conjunto no tiene señal aprendible, por lo que sirve como control negativo: una red entrenada sobre datos sin patrón no mejora al azar, a diferencia de lo que ocurre con Red Wine Quality.